

Пространственная репрезентация городов в песенных текстах на русском языке: анализ топонимов с использованием LLM



Злобин Дмитрий
Игоревич
ПЗАД-4
БСЦ231




Кияница Владислав
Игоревич
ПЗАД-4
БГП231



Холодов Тимур
Алексеевич
ПЗАД-3
БПЛТЛ232



Юрова Ксения
Валерьевна
ПЗАД-4
БГП231



Блуменау Марк Ильич
Департамент больших
данных и информационного
поиска

Распределение работы участников



**Злобин Дмитрий
Игоревич
ПЗАД-4
БСЦ231**

- Сбор класса под llama-cpp. Исходное тестирование
- Разметка трети тестового датасета
- Тестирование 3 уникальных моделей на различных гиперпараметрах (квантизованные Qwen3.5, Qwen3.6, llama разного количества параметров)
- Перенос агентской версии пайплайна в общий класс Разделение моделей на распознавание и геокодирование. Внедрение gemini-api. Рефакторинг кода
- Создание класса для кодирования тональности и эмоциональной окрашенности трека. Внедрение в этот класс модуля для перевода и выполнения такого кодирования на английской версии текстов



**Кияница Владислав
Игоревич
ПЗАД-4
БГП231**

- Разметка датасета песенных текстов: выделение топонимов
- Настройка логирования экспериментов и метрик в Weights & Biases
- Проведение серии экспериментов с разными моделями и параметрами распознавания
- Тестирование качества извлечения топонимов на размеченной части датасета
- Сравнение NER-подходов для русского языка: Natasha, spaCy, DeepPavlov / Stanza
- Доработка пайплайна после тестирования: очистка вывода моделей, унификация формата результатов, обработка исключений
- Подготовка итогового CSV-файла с топонимами, координатами, типами объектов, тональностью и метаданными песен



**Холодов Тимур
Алексеевич
ПЗАД-3
БПЛТЛ232**

- Написание основных классов для распознавания топонимов, геокодирования и обработки результатов
- Перенос отдельных функций пайплайна в единую объектно-ориентированную структуру
- Разделение логики на модули: загрузка данных, извлечение топонимов, геокодирование, оценка тональности и визуализация
- Проведение экспериментов с разными промптами, температурами генерации и ограничениями на формат ответа
- Настройка логирования экспериментов, метрик и ошибок через Weights & Biases
- Сравнение качества NER-моделей на вручную размеченной части датасета
- Анализ ошибок распознавания: пропущенные топонимы, ложные срабатывания, неправильное определение границ сущностей



**Юрова Ксения
Валерьевна
ПЗАД-4
БГП231**


- Анализ литературы по теме геопарсинга, NER и извлечения топонимов из текстов
- Изучение подходов к геотеппингу и геокодированию песенных текстов
- Сравнение API и инструментов для геотеппинга: Nominatim, GeoNames, Google Maps API
- Разметка датасета песенных текстов: выделение топонимов
- Проведение серии экспериментов с разными моделями и параметрами распознавания
- Сравнение NER-подходов для русского языка: Natasha, spaCy, DeepPavlov / Stanza
- Тестирование качества извлечения топонимов на размеченной части датасета
- Разработка MVP Streamlit-приложения для визуализации топонимов на карте

Постановка задачи и мотивация для ее выполнения

Несмотря на активное развитие и широкое применение методов машинного обучения в Digital Humanities, в частности NER, демонстрирующих высокую точность на качественно отредактированных текстах, легко обнаружить, что их эффективность существенно снижается при работе с песенными текстами, наполненными неформальной лексикой: например, слэнгом

Это привело нас к исследовательскому вопросу:


Как создать пайплайн для поиска и геокодирования неформальных, контекстных и сленговых топонимов в русскоязычных песенных текстах?



Существующие решения для похожих задач

MusicStand

Kuo & Samet, 2021



Идея для нашего проекта:
песни → нормализация текста → топонимы → координаты → карта

The Emotions of London

Heuser, Moretti & Steiner, 2016



Идея для нашего проекта:
топоним → контекст песни → тональность → карта

Данные и геономализация

01 / Hugging Face lyrics dataset

Корпус треков: текст + метаданные

Берём трек, исполнителя, название и полный текст песни

artist	title	lyrics	Топонимы
Boulevard Depo	Angry toy\$	Прихожу раньше, не то чтобы вовремя Захожу тихо, без шума и гонора ... Да мне хоть Купчино, хоть ЮВАО ... Иду по Арбату, и все меня палят	Купчино: район ЮВАО: АО Москвы Арбат: улица

пример строки из трека:

... Да мне хоть **Купчино** , хоть **ЮВАО** ...

Иду по **Арбату** , и все меня палят


район

улица

административный округ

02 / нормализация и геокодирование

OSM + Nominatim



03 / открытые базы, которые рассматривали

GeoNames

готовый справочник
геоназваний и координат

Wikidata

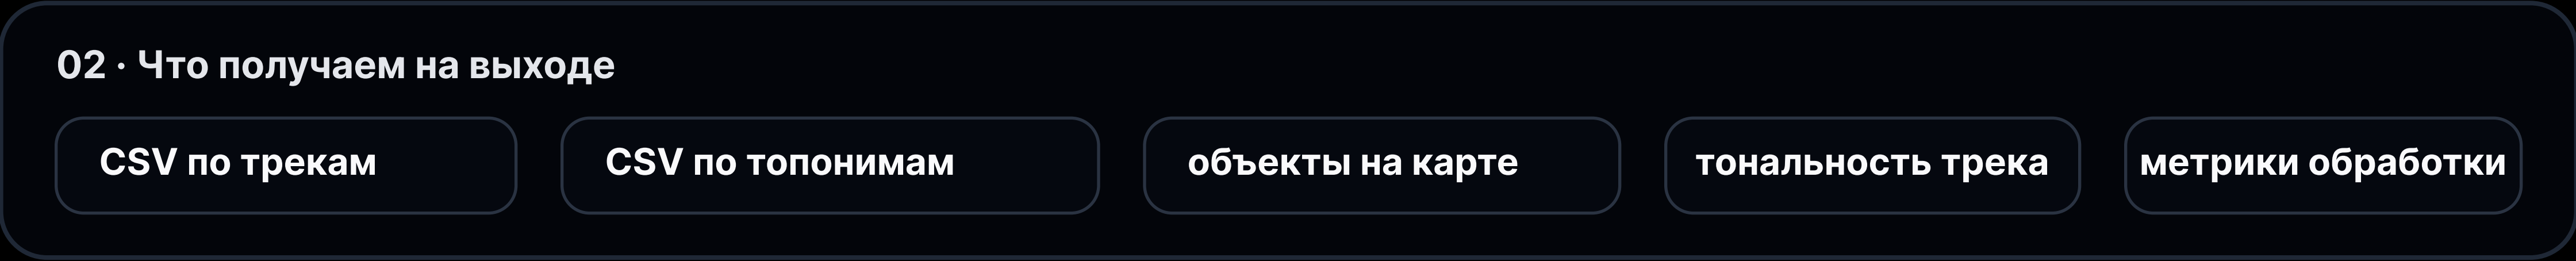
открытый граф знаний

Итоговая запись: трек → найденный топоним → нормализация → OSM/Nominatim address → lat/lon → проверка соответствия контексту песни

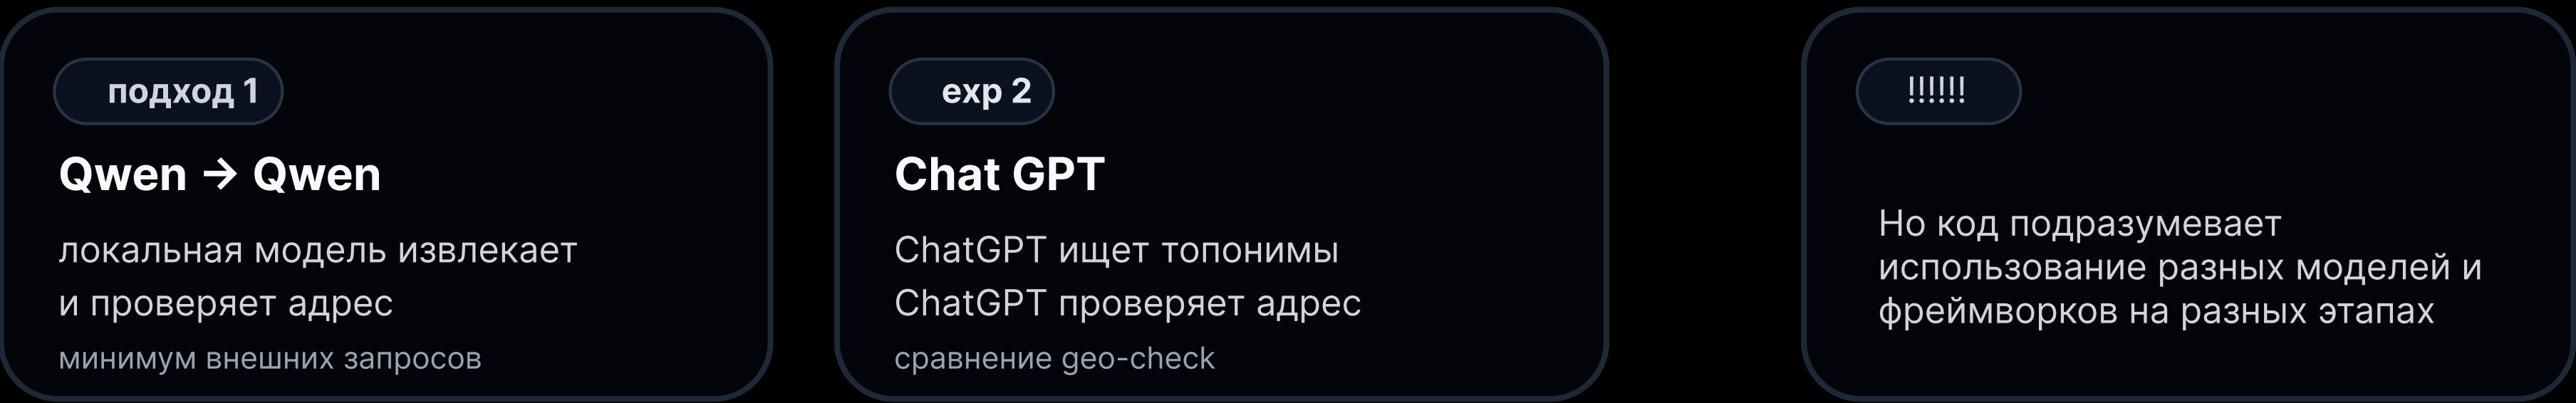
Реализованные подходы к решению задач

Пайплайн: от текста песни до координат, фильтрации адресов, тональности и метрик качества

01 · Основная цепочка обработки



03 · Реализованные подходы / эксперименты



Стэк технологий

Библиотеки:





- transformers
- huggingface_hub
- outlines
- pydantic
- tqdm
- llama-cpp-python
- bitsandbytes
- wandb
- torch
- langchain-core
- langchain-google-genai
- langgraph

Модели:

- Qwen3.6-35B-A3B-nomtp-Q5xl-ctx4608-mt1536-t01
- Qwen3.6-35B-A3B-nomtp-Q4xl-ctx8192
- Qwen3.6-35B-A3B-nomtp-MXFP4_MOE
- Qwen3.6-35B-A3B-Q5xl-ctx4608-eng
- Qwen3.5-35B-A3B-APEX
- GigaChat3.1-10B-mt512-t01
- llama-2-13b-qlora-q5km-ctx2048-t01
- Gherman/bert-base-NER-Russian
- natasha/slovnet-news-ner spacy/ru_core_news_lg stanza/ru
- Babelscape/wikineural-multilingual-ner


Метрики: обоснование и эксперименты

Главной являлись метрики precision, recall и их гармоническая: F1-score. Сделали такой выбор так как отсутствовал класс TN




Метрики: облако слов

Заранее предусмотрели логгирование FP и FN - топонимов в экспериментах



Overpredicted



Unpredicted

Метрики: логгирование

Логгирование делали через wandb

T-kholodov's workspacePersonal workspace

Saved just now

Runs15

Search runs


FilterGroupSortNew sweepColumns

NAME2 visualized	STATE	NOTES	CREATED	RUNTIME	MODEL	PROMPT	TEMP	CONTEXT_W	MAX_TOKEN	BACKEND	FR
GigaChat3.1-10B-mt512-t01	Finished	Тимур	2w ago	28m 26s	ai-sage/GigaChat3.1-10B-A1.8B-GGUF	# — Роль —	0.1	4096	512	-	-
gpt-5.4-mini	Finished	Final exper...	5h ago	24m 36s	gpt-5.4-mini	-	-	-	-	-	-
Qwen3.6-35B-A3B-GGUF	Finished	Final exper...	4h ago	1h 19m 31s	Qwen3.6-35B-A3B-GGUF	-	-	-	-	-	-
Qwen3.6-35B-A3B-GGUF	Crashed	Final exper...	7h ago	1h 6m 46s	Qwen3.6-35B-A3B-GGUF	-	-	-	-	-	-
Qwen3.6-35A3-M-Agent	Finished	Dima	23h ago	9m 17s	Qwen3.6-35A3-M-Agent	-	-	-	-	-	-
Qwen3.6-35A3-M-Agent	Finished	Dima	2d ago	16m 34s	Qwen3.6-35A3-M-Agent	-	-	-	-	-	-
Qwen3.6-35A3-M-Agent	Finished	Dima	2d ago	1h 24m 51s	Qwen3.6-35A3-M-Agent	-	-	-	-	-	-
Qwen3.6-35A3-M-Agent	Finished	Dima	1d ago	8m 9s	Qwen3.6-35A3-M-Agent	-	-	-	-	-	-
Qwen3.6-35A3-M-Agent	Finished	Dima	2d ago	17m 47s	Qwen3.6-35A3-M-Agent	-	-	-	-	-	-
classic_NER_spacy	Finished	classic NE...	2w ago	42s	spacy/ru_core_news_lg	-	-	-	-	spacy	cl
classic_NER_stanza	Finished	classic NE...	2w ago	58s	stanza/ru	-	-	-	-	stanza	cl
classic_NER_hf_gherman	Finished	classic NE...	2w ago	16s	Gherman/bert-base-NER-Russian	-	-	-	-	hf_gherman	cl
classic_NER_hf_wikineural	Finished	classic NE...	2w ago	17s	Babelscape/wikineural-multilingual-ni	-	-	-	-	hf_wikineural	cl
classic_NER_natasha	Finished	classic NE...	2w ago	14s	natasha/slovnet-news-ner	-	-	-	-	natasha	cl

Реализация MVP



Видео



Итог

1. Создана ручная обертка для запуска llama-cpp в LangGraph
2. Построен агентский пайплайн для инференса
3. Найдена оптимальная модель (вид+параметры)
4. Подготовлен сервис для визуализации найденных данных